

## Long Short Term Memory 기반의 운전자 행동 모니터링 시스템

Long short Term Memory Based Driver Behavior Monitoring System

---

저자 (Authors)	양진호, 이현수, 최우영, 정정주 Jin Ho Yang, Hyun Soo Lee, Woo Young Choi, Chung Choo Chung
출처 (Source)	<a href="#">한국자동차공학회 춘계학술대회</a> , 2018.6, 862-867(6 pages)
발행처 (Publisher)	<a href="#">한국자동차공학회</a> The Korean Society Of Automotive Engineers
URL	<a href="http://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE07546710">http://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE07546710</a>
APA Style	양진호, 이현수, 최우영, 정정주 (2018). Long Short Term Memory 기반의 운전자 행동 모니터링 시스템. 한국자동차공학회 춘계학술대회, 862-867
이용정보 (Accessed)	경북대학교 155.230.47.*** 2021/06/15 14:37 (KST)

---

### 저작권 안내

DBpia에서 제공되는 모든 저작물의 저작권은 원저작자에게 있으며, 누리미디어는 각 저작물의 내용을 보증하거나 책임을 지지 않습니다. 그리고 DBpia에서 제공되는 저작물은 DBpia와 구독계약을 체결한 기관소속 이용자 혹은 해당 저작물의 개별 구매자가 비영리적으로만 이용할 수 있습니다. 그러므로 이에 위반하여 DBpia에서 제공되는 저작물을 복제, 전송 등의 방법으로 무단 이용하는 경우 관련 법령에 따라 민, 형사상의 책임을 질 수 있습니다.

### Copyright Information

Copyright of all literary works provided by DBpia belongs to the copyright holder(s) and Nurimedia does not guarantee contents of the literary work or assume responsibility for the same. In addition, the literary works provided by DBpia may only be used by the users affiliated to the institutions which executed a subscription agreement with DBpia or the individual purchasers of the literary work(s) for non-commercial purposes. Therefore, any person who illegally uses the literary works provided by DBpia by means of reproduction or transmission shall assume civil and criminal responsibility according to applicable laws and regulations.

# Long Short Term Memory 기반의 운전자 행동 모니터링 시스템

양진호\*<sup>1)</sup>, 이현수<sup>1)</sup>, 최우영<sup>1)</sup>, 정정주\*\*<sup>2)</sup>

한양대학교 전기공학과<sup>1)</sup>, 한양대학교 전기생체공학부<sup>2)</sup>

## Long Short Term Memory Based Driver Behavior Monitoring System

Jin Ho Yang\*<sup>1)</sup> · Hyun Soo Lee<sup>1)</sup> · Woo Young Choi<sup>1)</sup> · Chung Choo Chung\*\*<sup>2)</sup>

<sup>1)</sup> Department of Electrical Engineering, Hanyang University, 222 Wangsimni-ro, Seongdong-gu, Seoul 04763, Korea

<sup>2)</sup> Division of Electrical and Biomedical Engineering, Hanyang University, 222 Wangsimni-ro, Seongdong-gu, Seoul 04763, Korea

**Abstract** : The driver behavior monitoring system is a system for observing unexpected maneuvers of a driver and alerting dangerous situation to prevent traffic accidents. In this paper, we propose the ‘Long Short Term Memory (LSTM)’ based driver behavior monitoring system. The LSTM is suitable for monitoring driver’s behavior because it is easy to process long term sequential data through selective memory algorithm using the partially storing method. The verification about the prediction simulation was conducted by comparing the actual driving data and the prediction results using the LSTM which implemented by computer language..

**Key words** : Deep Learning(딥 러닝), Long Short Term Memory(장단기 메모리), Recurrent Neural Network(인공 순환신경망), Driver Behavior Monitoring(운전자 행동 관찰), Steering Prediction(조향 예측), Time Sequential Data(시간 순서 데이터)

### Nomenclature

$c_{(t)}$  : long term state vector at time step of ‘t’  
 $h_{(t)}$  : short term state vector at time step of ‘t’  
 $X_{(t)}$  : input vector at time step of ‘t’  
 $Y_{(t)}$  : output vector at time step of ‘t’  
 $\phi(\cdot)$  : activation functions  
 $W_x$  : RNN weight for the input of current time  
 $W_y$  : RNN weight for the output of current time  
 $b$  : RNN bias term for each neuron  
 $W_{xi}$  : LSTM weight of  $i_{(t)}$  to input vector  
 $W_{xf}$  : LSTM weight of  $f_{(t)}$  to input vector  
 $W_{xo}$  : LSTM weight of  $o_{(t)}$  to input vector  
 $W_{xg}$  : LSTM weight of  $g_{(t)}$  to input vector

$W_{hi}$  : LSTM weight of  $i_{(t)}$  to previous short-term state  
 $W_{hf}$  : LSTM weight of  $f_{(t)}$  to previous short-term state  
 $W_{ho}$  : LSTM weight of  $o_{(t)}$  to previous short-term state  
 $W_{hg}$  : LSTM weight of  $g_{(t)}$  to previous short-term state  
 $b_i$  : LSTM bias of  $i_{(t)}$  layers  
 $b_f$  : LSTM bias of  $f_{(t)}$  layers  
 $b_o$  : LSTM bias of  $o_{(t)}$  layers  
 $b_g$  : LSTM bias of  $g_{(t)}$  layers  
 $c_0^{(t)}$  : lateral position offset at time step of ‘t’  
 $c_1^{(t)}$  : heading angle at time step of ‘t’  
 $c_2^{(t)}$  : curvature / 2 at time step of ‘t’  
 $c_3^{(t)}$  : curvature derivative / 6 at time step of ‘t’  
 $v_{long}^{(t)}$  : longitudinal velocity at time step of ‘t’  
 $v_{lat}^{(t)}$  : lateral velocity at time step of ‘t’

\* Jin Ho Yang, E-mail: jjz0426@hanyang.ac.kr

\*\* Corresponding author, E-mail: cchung@hanyang.ac.kr

$\delta_{des}^{(t)}$  : desired steering angle at time step of 't'  
 $\delta_{des}^{(t+1)}$  : desired steering angle at time step of 't+1'  
 $\delta_{drv}^{(t+1)}$  : driver's steering angle at time step of 't+1'

## 1. 서 론

통계적으로 교통사고 원인의 90% 이상은 운전자의 부주의<sup>1)</sup>이다. 운전보조자가 동승한 경우, 운전자의 졸음, 전방 주시 태만 등의 부주의가 발생하더라도 교통사고로 직결되지 않을 수 있다. 그러나 단독 운전 중에는 운전자 자신의 부주의한 행동에 대한 인지가 불가능하기 때문에 다양한 운전자 행동 모니터링 시스템(Driver Behavior Monitoring System)에 대한 연구<sup>2) 3)</sup>가 진행되고 있다.

실제로 다양한 센서를 이용하여 데이터를 방대하게 취득하고 순환 인공신경망(Recurrent Neural Network)을 이용하면 운전자의 다양한 의도를 예측<sup>4)</sup>할 수 있다. 하지만 비전 센서(Vision Sensor)를 이용하여 운전자의 안면 부위(Facial Region) 또는 수부(Hands)를 촬영하는 방식<sup>5-7)</sup>은 운전자를 관찰하고 행동을 예측하는데 효과적일 수 있지만 기준이 모호하며 실시간으로 분석하기에 데이터의 양이 방대하다.

$$Y_{(t)} = \phi(X_{(t)}^T \cdot W_x + Y_{(t-1)}^T \cdot W_y + b) \quad (1)$$

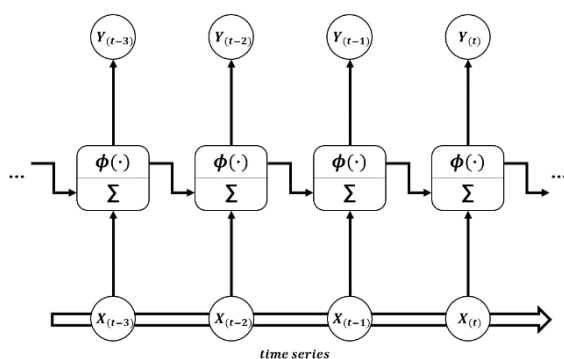


Fig. 1 Schematic diagram of recurrent neural network

순환 인공신경망을 이루는 순환 뉴런(Recurrent Neuron)은 현재 시간의 입력 벡터와 이전 시간에서 예측된 출력 벡터를 다시 받아 현재 출력을 연산하는 단위이다. 그래서 순환 인공신경망은 Fig.

1 처럼 순환 뉴런들의 순차적인 나열로 구성된다. 식 (1) 을 통해 현재 시간의 출력은 현재 시간의 입력과 이전 시간의 출력에 대한 함수인 것을 알 수 있다. 따라서 구조적으로 봤을 때 일반적으로 순환 인공신경망은 시간 순서 데이터(Time Sequential Data)를 재귀적으로 학습하기에 적합하다.

하지만 순환 인공신경망을 통해 학습을 할 때, 역전파(Back Propagation)가 진행되는 과정에서 데이터의 수가 길거나 방대하여 인공 뉴런과 뉴런 사이가 멀 경우, 그라디언트(Gradient)가 희석되거나 소멸되는 문제가 발생<sup>8) 9)</sup>하게 된다. 결과적으로 예측 정확도가 크게 떨어지거나 오차가 커지게 된다. 따라서 본 논문에서는 순환 인공신경망을 개량한 장단기 메모리(Long Short-term Memory)를 사용한다. 장단기 메모리는 S. Hochritter, J. Shumidhuber가 1997년에 제안<sup>10)</sup>한 개념으로 긴 시간 순서 데이터를 학습시키는데 용이하며 장단기 메모리 기반 학습으로 주행 데이터를 학습<sup>11)</sup>한 사례도 있다.

본 논문에서는 실제 주행 데이터를 통해 얻은 시간 순서 데이터를 활용하여, 장단기 메모리 기반 학습을 통해 주행 시 요구되는 조향각을 예측한다. 예측한 조향각과 입력 받은 조향각을 비교함으로써 운전자의 행동을 모니터링하는 시스템을 제안한다. 구현된 장단기 메모리 성능은 정확도와 오차를 산출하는 방식을 통해 검증했다.

## 2. 장단기 메모리(LSTM)

순환 인공신경망의 개량된 형태인 장단기 메모리는 기본적인 단위 셀(Cell)이 Fig. 2 처럼 서로 다른 4개의 완전연결층(Fully-connected Layer)과 3개의 게이트(Gate)로 구성되고 매 시간 단계(Time Step)마다 입력 벡터  $X_{(t)}$ 와 2가지 상태 벡터  $h_{(t)}$ ,  $c_{(t)}$ 를 받는 구조<sup>12) 13)</sup>를 가진다. 현재 입력 벡터  $X_{(t)}$ 와 이전 단계 상태 벡터(Previous Short Term State Vector)  $h_{(t-1)}$ 는 서로 다른 4개의 완전연결층에 학습을 시킨다.

주 층(Main Layer)인  $g_{(t)}$ 는 후보 은닉 상태(Candidate Hidden State)를 의미하며 쌍곡선 탄젠트(Hyperbolic Tangent) 활성화 함수(Activation Function)를 사용해서  $X_{(t)}$ 와  $h_{(t-1)}$ 를 통해 다음 잠정적 상태를 계산하는 역할을 한다. 즉,  $g_{(t)}$ 는 그대로 출력

되지 않고 연산 과정을 통해 일부만 장기 상태 (Long Term State)에 부분적으로 저장된다. 이는 식 (2)와 같다.

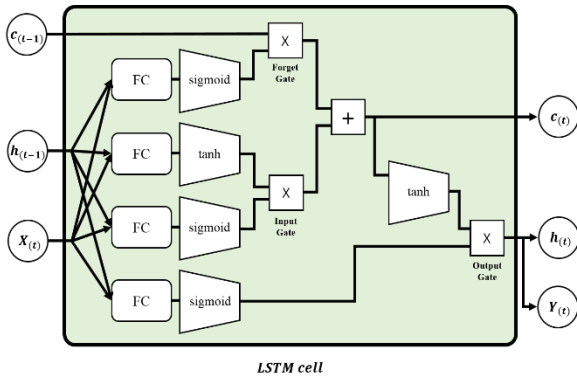


Fig. 2 Schematic diagram of LSTM cell

$$g_{(t)} = \tanh(W_{xg}^T \cdot X_{(t)} + W_{hg}^T \cdot h_{(t-1)} + b_g) \quad (2)$$

나머지 3개 층은 시그모이드(Sigmoid)라는 로지스틱(Logistic) 활성화 함수가 사용되기 때문에 0과 1 사이의 출력을 갖는다. 따라서 요소 별 곱셈 연산(Element-wise Multiplication)을 통해 게이트 제어기(Gate Controller)로 사용할 수 있다.  $i_{(t)}$ 가 제어하는 입력 게이트(Input Gate)는  $g_{(t)}$ 의 일부를 장기 상태에 더하는 연산을 담당한다. 이전 시간의  $c_{(t-1)}$ 는 삭제 게이트(Forget Gate)를 지나면서 일부 정보를 삭제하고 입력 게이트를 통과해 지나온 또 다른 정보를 더한다. 이 과정이 아래 식 (3), (4)에 나타나 있다.

$$f_{(t)} = \sigma(W_{xf}^T \cdot X_{(t)} + W_{hf}^T \cdot h_{(t-1)} + b_f) \quad (3)$$

$$i_{(t)} = \sigma(W_{xi}^T \cdot X_{(t)} + W_{hi}^T \cdot h_{(t-1)} + b_i) \quad (4)$$

식 (5)는  $o_{(t)}$ 가 제어하는 출력 게이트(Output Gate)가 읽혀지는 장기 상태와 현재 상태의 출력( $h_{(t)}$ ,  $Y_{(t)}$ )을 제어한다는 것을 의미한다.

$$o_{(t)} = \sigma(W_{xo}^T \cdot X_{(t)} + W_{ho}^T \cdot h_{(t-1)} + b_o) \quad (5)$$

현재 시간의  $c_{(t)}$ 는 더 이상의 변환 과정없이 그대로 출력되며 복사된  $c_{(t)}$ 는  $\tanh$  함수 연산과 출력 게이트를 거쳐  $h_{(t)}$ 로 출력된다. 또한  $y_{(t)}$ 는  $h_{(t)}$ 와 동일하며 은 식 (6), (7)를 통해 알 수 있

다.

$$c_{(t)} = f_{(t)} \times c_{(t-1)} + i_{(t)} \times g_{(t)} \quad (6)$$

$$Y_{(t)} = h_{(t)} = o_{(t)} \times \tanh(c_{(t)}) \quad (7)$$

이와 같이 장단기 메모리는 장기와 단기 상태 벡터를 이용한 정보의 선별을 통해 순환 인공신경망이 가지는 문제를 해결할 수 있으며 길이가 긴 시간 순서 데이터를 처리하여 예측하는데 적합한 모델이다.

### 3. 실험 구성

#### 3.1 실험 데이터 수집 환경

운전자가 Fig. 3의 실험 차량으로 Fig. 4의 한국교통안전공단 자동차안전연구원(Korea Automobile Testing & Research Institute, KATRI) 주행시험장 고속주회로의 직선, 완화, 곡선 구간을 따라 주행했다. 운전자는 계기판을 기준으로 120 kph의 속력과 차로 중앙의 위치를 유지하면서 약 5분 간 주행했다. 이 때, 매  $10^{-2}$  s 마다 차량 데이터를 수집했다. 고속주회로 한 바퀴의 직선, 완화, 곡선 구간의 길이는 각각 1,934 m, 1,644 m, 1,462 m이며 곡선 구간의 곡선 반지름은 360 m 이다.

#### 3.2 실험 데이터 세트

취득한 전체 데이터 세트 중 학습을 위해 좌우차선의 클로소이드(Clothoid) 곡선 계수 평균값( $C_0 \sim C_3$ ), 중형방향 속도 및 요 각속도(Yaw Rate)를, 예측값과의 비교를 위해 조향각 데이터를 추출하여 재구성함으로써 새로운 데이터 세트를 생성했다. 재구성한 데이터 세트는 차원이 8이며 총 30,867개의 열로 구성했다.



Fig. 3 Test vehicle (Tucson LX20)



Fig. 4 Proving ground (KATRI)

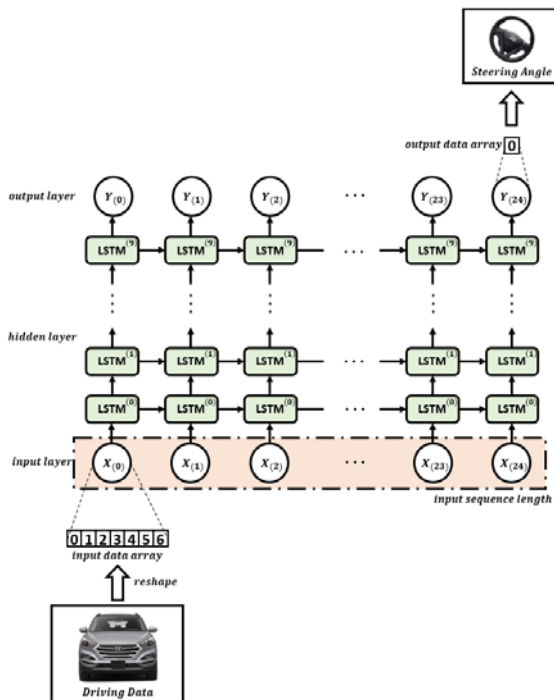


Fig. 5 Schematic diagram of LSTM architecture

### 3.3 인공지능망 아키텍처 및 학습방법

데이터 분석에 사용한 장단기 메모리는 취득한 여러 데이터 입력을 통해 한 개의 예측 데이터를 출력하는 Seq2Vec (Sequence-to-vector) 형태이며 윈도우 운영체제에서 아나콘다(Anaconda) 환경의 텐서플로우(TensorFlow)를 연동한 파이썬(Python) 언어를 이용하여 Fig. 5의 구조를 구현했다. 구현한 장단기 메모리는 10개의 은닉층(Hidden Layer)을 가지며 시계열 길이(Time Sequence Length)는 25단계를 단위로 그 다음 시간 단계를 예측해 나가도

록 했다.

추출 후 재구성한 30,867개의 차량 데이터 세트는 75:25의 비율로 분할하여 23,150개의 데이터는 연습 시간(Training Session)에, 7,717개의 데이터는 시험 시간(Testing Session) 학습에 적용하였다. 손실 함수(LossFunction)를 최소화하기 위해 그래디언트 감소(Gradient Descent) 방법 중 적응 모멘트 추정(Adaptive Moment Estimation) 방식을 이용하여 0.01의 학습률(LearningRate)로 최적화하였다. 또한 전체 데이터 세트에 대해 1,000번의 반복(Iterations) 학습을 진행했다.

## 4. 시뮬레이션 결과

구현한 장단기 메모리는 재구성한 데이터 세트 중 조향각을 제외한 7차원의 현재 정보를 입력으로 받아 조향각 정보를 예측하여 출력한다. 또한 예측된 조향각과 실제 입력된 조향각을 비교하는 과정을 거침으로써 올바른 차선 유지를 위한 조향각 예측 성능을 검증하였다.




Fig. 6 Plot of prediction result




Fig. 7 Plot of RMSE



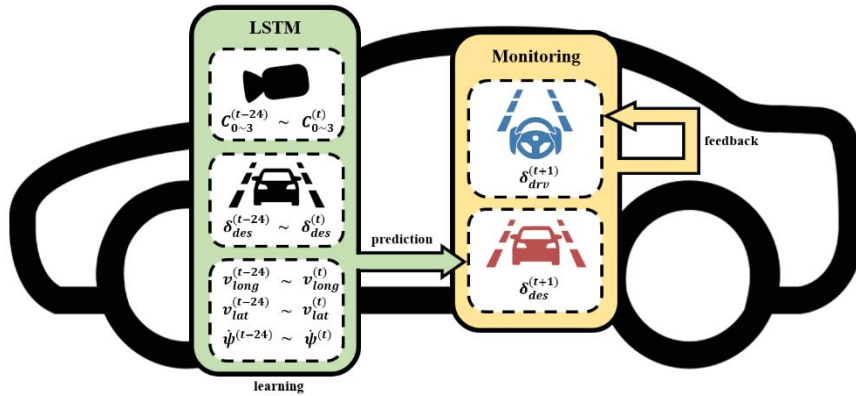


Fig. 8 Schematic diagram of 'Driver Behavior Monitoring System'

Fig. 6은 실제 차량이 주행을 통해 수집한 차량 데이터의 조향각(Blue, Solid Line)과 장단기 메모리 기반 학습을 통해 예측한 조향각(Red, Dot)을 나타낸다. 구현한 LSTM의 성능을 검증하기 위해 정확도와 근평균제곱오차(Root Mean Square Error, RMSE)를 이용했다. 정확도와 RMSE는 예측값과 실제값의 차이를 활용해 각각 산출하였다. 최종적인 연습 정확도와 시험 정확도는 각각 97.74%, 91.23%이며 학습을 마친 후에 RMSE는 Fig. 7에서 0.013임을 확인했다.

위와 같이 학습된 장단기 메모리는 시계열 차량 데이터를 토대로 올바른 조향각  $\delta_{des}^{(t+1)}$ 을 예측한다. 그리고 실제 운전자가 다음 시간 단계에서 입력한 조향각  $\delta_{drv}^{(t+1)}$ 과의 일치성을 판단하는 관찰 과정으로 운전자의 잘못된 조향 행동을 검출할 수 있다. 검출된 행동은 지속적인 보조를 통해 운전자가 인지할 수 있도록 한다. 이와 같은 운전자 행동 모니터링 시스템을 Fig. 8과 같이 구성할 수 있다.

## 5. 결 론

본 논문에서는 인공 순환신경망(RNN)의 변형된 구조인 장단기 메모리(LSTM)를 이용하여 운전자의 조향 조작 행동을 학습하였으며 운전자의 조향 조작을 예측함으로써 운전자 행동 모니터링 시스템(Driver Behavior Monitoring System)을 제시했다. 특히 선회 주행 시 차량은 곡률 변화가 완화된 클

로소이드 곡선 형태의 차로를 추종하기 때문에 조향 조작의 급격한 변화가 없어 학습 및 예측에 적합했다. 장단기 메모리는 긴 시계열 차량 데이터를 처리하는 과정에서 2가지 상태 벡터를 이용한 선택적 기억 방법으로 높은 정확도와 낮은 오차를 가지는 것을 확인했다. 이를 통해 인접 차량들(Surround Vehicles)과의 상대 거리, 상대 속도 등을 같이 학습한다면 복잡한 주행 상황에서 운전자의 다양한 행동을 모니터링하는데 큰 도움이 될 것으로 판단한다. 또한 자율 주행에 사용되는 차선유지 보조시스템(Lane Keeping Assistant System)을 모니터링하여 오작동(Malfunction)을 검출하는 데에도 적용이 가능하다고 생각한다.

## ACKNOWLEDGEMENT

이 연구는 산업통상자원부 및 산업기술평가관리원(KEIT) 연구비 지원에 의한 연구임(10082585, 자율주행이 가능한 딥러닝 기반 개방형 EV 차량 플랫폼 기술개발).

## References

- 1) S. Y. Wang, G. B. Chi, C. X. Jing, X. M. Dong, C.-P. Wu, and L.P. Li, "Trends in Road Traffic Crashes and Associated Injury and Fatality in the Peoples Republic of China, 1951-1999," Injury Control and Safety Promotion, Vol.10, No.1-2, pp.83-87, 2003.

- 2) T. Brandt, R. Stemmer, and A. Rakotonirainy, "Affordable Visual Driver Monitoring System for Fatigue and Monotony," IEEE International Conference on Systems, Man and Cybernetics, Vol. 7, pp.6451-6456, 2004.
- 3) G. Castignani, T. Derrmann, R. Frank, and T. Engel, "Driver Behavior Profiling Using Smartphones: A Low-Cost Platform for Driver Monitoring." IEEE Intelligent Transportation Systems Magazine Vol.7, No.1, pp.91-102, 2015.
- 4) O. Olabiyi, E. Martinson, V. Chintalapudi, and R. Guo, "Driver Action Prediction Using Deep (Bidirectional) Recurrent Neural Network," Preprint of Submission IEEE The International Conference on Intelligent Transportation Systems (ITSC) (arXiv:1706.02257), 2017.
- 5) M. S. Devi, and P. R. Bajaj, "Driver Fatigue Detection Based on Eye Tracking," 1st IEEE International Conference on Emerging Trends in Engineering and Technology, pp.649-652, 2008.
- 6) E. Wahlstrom, O. Masoud, and N. Papanikolopoulos, "Vision-Based Methods for Driver Monitoring," Proceedings of IEEE Intelligent Transportation Systems, Vol. 2, pp.903-908, 2003.
- 7) J. J. Lee, S. J. Kim, J. Jung, H G, and K. R. Park, "Vision-Based Method for Detecting Driver Drowsiness and Distraction in Driver Monitoring System," Optical Engineering, Vol.50, No.12, 127202, pp.1-24, 2011.
- 8) Y. Bengio, P. Simard, and P. Frasconi, "Learning Long-term Dependencies with Gradient Descent Is Difficult," IEEE Transactions on Neural Networks, Vol.5, No.2, pp.157-166, 1994.
- 9) S. Hochreiter, "Recurrent Neural Net Learning and Vanishing Gradient," International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems, Vol. 6, No.2, pp.107-116, 1998.
- 10) S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," Neural Computation, Vol.9, No.8, pp.1735-1780, 1997.
- 11) H. W. Kim and S. H. Park, "LSTM Based LKAS Yaw Rate Prediction Model Using Lane Information and Steering Angle," Transaction of KSAE, Vol.26, No.2, pp.279-287, 2018.
- 12) A. Géron, "Hands-On Machine Learning with Scikit-Learn and TensorFlow," O'REILLY Media, 2017.
- 13) I. Goodfellow, Y. Bengio, and A. Courville, "Deep Learning," MIT Press, 2016